HỌC VIỆN CÔNG NGHỆ BƯU CHÍNH VIỄN THÔNG

KHOA CÔNG NGHỆ THÔNG TIN

Môn: THỰC TẬP CƠ SỞ

BÁO CÁO DỰ ÁN

"Xây dựng hệ thống sửa lỗi chính tả cho tiếng Việt"

Sinh viên thực hiện: Phạm Quang Anh

Mã sinh viên: B23DCCN044

Lớp: D23CQCN02-B

Nhóm: 11

Giảng viên hướng dẫn: TS. Kim Ngọc Bách

Hà Nội 2026

LỜI CẢM ƠN

Lời đầu tiên, chúng em xin gửi lời cảm ơn chân thành tới Học viện Công nghệ Bưu chính Viễn thông vì đã tạo điều kiện cho chúng em được tham gia môn học Thực tập cơ sở. Đây là một môn học rất bổ ích và thiết thực, trang bị cho chúng em những kiến thức nền tảng quan trọng trong lĩnh vực Công nghệ thông tin.

Chúng em đặc biệt biết ơn thầy Kim Ngọc Bách, người đã tận tâm dẫn dắt chúng em trong suốt hành trình chinh phục môn học này. Thầy không chỉ truyền đạt những kiến thức chuyên sâu một cách dễ hiểu mà còn nhiệt tình giải đáp mọi thắc mắc, chia sẻ những kinh nghiệm thực tế quý báu, giúp chúng em có cái nhìn toàn diện và sâu sắc hơn.

Quá trình hoàn thành báo cáo bài tập lớn là một thử thách không nhỏ đối với chúng em. Tuy thời gian có hạn và gặp phải không ít khó khăn, nhưng với sự hướng dẫn tận tình của thầy và tinh thần học hỏi, nỗ lực không ngừng, chúng em đã cố gắng hết sức để hoàn thành báo cáo này một cách tốt nhất.

Kính mong thầy đánh giá và góp ý để chúng em có thể rút kinh nghiệm, hoàn thiện bản thân và phát triển hơn nữa trên con đường học tập sắp tới.

1. Giới thiệu dự án

1.1 Lý do chọn đề tài

Sửa lỗi chính tả tiếng Việt là yếu tố quan trọng để nâng cao chất lượng các hệ thống xử lý dữ liệu dựa trên văn bản. Sửa lỗi chính tả cho tiếng Việt góp một phần lớn trong công việc tiền xử lý dữ liệu, tinh chỉnh và cải thiện kết quả từ tác vụ OCR nhằm số hóa tài liệu

1.2 Mục tiêu cần đạt được

Dự án tập trung vào việc nghiên cứu và triển khai hệ thống tự động hóa quá trình kiểm tra và sửa lỗi văn bản, hướng tới các mục tiêu cụ thể sau:

- **Xây dựng mô hình lõi hiệu quả:** Phát triển hệ thống dựa trên kiến trúc Transformer hoặc Sequence-to-Sequence (Seq2Seq) để hiểu sâu ngữ cảnh của câu.
- **Độ chính xác cao:** Đạt tỷ lệ sửa lỗi chính xác ít nhất **85%** trên các tập dữ liệu chuẩn thông qua việc tinh chỉnh (fine-tuning) các mô hình tiền huấn luyện như ViT5 hoặc BARTpho.
- **Xử lý đa dạng loại lỗi:**
    - **Lỗi gõ máy:** Khắc phục các lỗi sai ký tự, thiếu dấu hoặc sai quy tắc gõ Telex/VNI.
    - **Lỗi ngữ pháp:** Gợi ý sửa các từ dùng sai ngữ cảnh dựa trên xác suất ngôn ngữ.
    - **Lỗi OCR:** Đặc biệt tối ưu hóa khả năng nhận diện và sửa các lỗi do quét văn bản (OCR) như nhầm lẫn giữa các ký tự có hình dáng tương đồng (0-o, l-i, q-g).
- **Khả năng mở rộng:** Triển khai hệ thống bằng thư viện Hugging Face Transformers hoặc PyTorch để đảm bảo tính linh hoạt và dễ dàng tích hợp vào các ứng dụng thực tế.

1.3. Tính ứng dụng

Hệ thống sửa lỗi chính tả có khả năng triển khai thực tế trong nhiều lĩnh vực:

- **Chuẩn hóa văn bản hành chính:** Hỗ trợ soạn thảo văn bản, giảm thiểu sai sót trong các giấy tờ quan trọng của tổ chức và doanh nghiệp.
- **Tối ưu hóa số hóa tài liệu (OCR):** Tự động chỉnh sửa các lỗi phát sinh sau khi quét tài liệu cũ hoặc văn bản viết tay, giúp quá trình lưu trữ số đạt độ chính xác cao.
- **Hỗ trợ biên tập nội dung:** Tích hợp vào các nền tảng báo chí, blog và mạng xã hội để đảm bảo tính chuyên nghiệp của nội dung trước khi xuất bản.
- **Cải thiện trải nghiệm người dùng:** Tích hợp vào bộ gõ trên thiết bị di động để gợi ý từ đúng ngay khi người dùng nhập liệu sai.

1.4. Giá trị học thuật

Dự án mang lại những đóng góp quan trọng về mặt nghiên cứu trong lĩnh vực Xử lý ngôn ngữ tự nhiên (NLP):

- **Nghiên cứu kiến trúc Transformer cho tiếng Việt:** Khám phá hiệu quả của mô hình **ViT5** (VietAI) trong việc giải quyết đặc thù ngữ pháp và thanh điệu phức tạp của tiếng Việt.
- **Ứng dụng mô hình Truy xuất - Sinh (RAG):** Đánh giá vai trò của khung làm việc **UniversalRAG** trong việc giảm thiểu hiện tượng "ảo giác" (hallucination) của AI bằng cách truy xuất tri thức từ kho dữ liệu thực tế.
- **Xử lý đa cấp độ thông tin (Multi-granularity):** Nghiên cứu cách hệ thống chọn lọc dữ liệu từ cấp độ từ đơn đến đoạn văn để tối ưu hóa kết quả sửa lỗi.
- **Chuẩn hóa quy trình Denoising:** Đóng góp vào phương pháp huấn luyện mô hình bằng cách tạo nhiễu giả lập (Noising) từ các tập dữ liệu chuẩn như **VNTC** và **Viwiki** để tăng cường khả năng chống nhiễu cho mô hình.

2. Cơ sở lý thuyết và công nghệ sử dụng

2.1. Mô hình ViT5 (VietAI)

- **Đặc điểm:** ViT5 là mô hình Transformer kiến trúc Encoder-Decoder được tiền huấn luyện (pre-trained) chuyên biệt cho tiếng Việt.
- **Ưu điểm:** Hiểu sâu sắc cấu trúc ngữ pháp và từ vựng tiếng Việt, giúp thực hiện các tác vụ sinh văn bản (text-to-text) như sửa lỗi chính tả với độ chính xác cao.

2.2. Khung làm việc UniversalRAG

- **Cơ chế Retrieval-Augmented Generation (RAG):** Hệ thống không chỉ dựa vào bộ nhớ của mô hình mà còn thực hiện truy xuất thông tin từ một kho tri thức bên ngoài trước khi đưa ra kết quả.
- **Truy xuất đa cấp độ (Multi-granularity):** Cho phép hệ thống lấy ra các đơn vị thông tin từ cấp độ từ đơn, cụm từ đến đoạn văn để bổ trợ cho việc sửa lỗi.
- **Router thông minh:** Bộ điều hướng tự động xác định loại dữ liệu và mức độ chi tiết cần thiết để hỗ trợ mô hình Transformer khi gặp các lỗi OCR nặng hoặc từ chuyên ngành hiếm gặp.

2.3. Thư viện Hugging Face và PyTorch

- **Hugging Face Transformers:** Cung cấp các công cụ tối ưu để tải, huấn luyện và triển khai các mô hình ngôn ngữ lớn như ViT5 một cách nhanh chóng.
- **PyTorch Framework:** Nền tảng tính toán tensor mạnh mẽ, hỗ trợ xây dựng và tinh chỉnh các mạng nơ-ron sâu phức tạp.

2.4. Kiến trúc Transformer và Mô hình Seq2Seq

- **Mô hình Sequence-to-Sequence (Seq2Seq):** Là kiến trúc cho phép chuyển đổi một chuỗi đầu vào (câu chứa lỗi) thành một chuỗi đầu ra (câu đã sửa) có độ dài khác nhau.

- **Cơ chế Attention:** Thành phần cốt lõi của Transformer, giúp mô hình tập trung vào các từ mang tính quyết định ngữ cảnh trong câu thay vì xử lý tuần tự, từ đó xử lý tốt các lỗi ngữ pháp phức tạp.
- **Mô hình tiền huấn luyện (Pre-trained Models):** Dự án sử dụng **ViT5** hoặc **BARTpho** – những mô hình đã học qua hàng tỷ câu tiếng Việt, giúp rút ngắn thời gian huấn luyện và tăng độ chính xác đáng kể khi tinh chỉnh (Fine-tuning).

2.5. Phương pháp huấn luyện và Tập dữ liệu đặc thù

- **VNTC (Vietnamese Typographical Corpus):** Tập dữ liệu chuyên biệt về các lỗi gõ phím (typo) thường gặp ở người Việt, cung cấp các mẫu lỗi dấu và hoán vị ký tự sát với thực tế.
- **Viwiki-Spelling Dataset:** Tập dữ liệu sửa lỗi chính tả dựa trên Wikipedia, cung cấp các cặp câu chuẩn giúp mô hình học được từ vựng phong phú và cấu trúc câu phức tạp.
- **Kỹ thuật Fine-tuning:** Quá trình huấn luyện lại các mô hình pre-trained trên sự kết hợp của VNTC và Viwiki-Spelling để tối ưu hóa khả năng nhận diện lỗi trong môi trường thực tế.

3. Phân tích yêu cầu dự án

3.1. Phân tích loại lỗi mục tiêu

- **Lỗi do bộ gõ (Typo):** Bao gồm sai lỗi dấu , sai trật tự ký tự hoặc gõ nhầm phím lân cận.
- **Lỗi do nhận diện OCR:** Các lỗi biến dạng ký tự thường gặp như nhầm lẫn giữa chữ và số (o-0, i-1), nhầm lẫn ký tự hình dáng giống nhau (d-đ, q-g).
- **Lỗi ngữ cảnh:** Sử dụng từ đúng chính tả nhưng sai ý nghĩa ngữ pháp trong câu (ví dụ: "đọc chuyện" thay vì "đọc truyện").

3.2. Yêu cầu về dữ liệu huấn luyện và truy xuất

- **Tăng cường dữ liệu (Data Augmentation):** Áp dụng kỹ thuật Noising lên tập Viwiki-Spelling để giả lập các biến dạng OCR, tạo ra tập dữ liệu đa dạng cho mô hình học.
- **Xây dựng kho tri thức (Knowledge Base):** Sử dụng các văn bản chuẩn từ Viwiki-Spelling để xây dựng cơ sở dữ liệu vector, phục vụ cho quá trình truy xuất của UniversalRAG.
- **Đảm bảo tính cân bằng:** Kết hợp VNTC và Viwiki-Spelling theo tỷ lệ phù hợp để mô hình không bị thiên kiến (bias) quá mức vào một loại lỗi nhất định.

3.3. Thiết kế quy trình thực thi (Pipeline)

- **Giai đoạn Truy xuất (Retrieval):** Khi nhận đầu vào, hệ thống dùng UniversalRAG để tìm các cụm từ chuẩn có độ tương đồng cao trong kho dữ liệu.
- **Giai đoạn Tổng hợp (Fusion):** Thông tin truy xuất được kết hợp cùng câu lỗi ban đầu để đưa vào mô hình Transformer.
- **Giai đoạn Sửa lỗi (Generation):** Mô hình ViT5/BARTpho thực hiện quá trình giải mã (decode) để sinh ra câu hoàn chỉnh với độ chính xác mục tiêu trên 85%.

4. Kế hoạch thực hiện dự án

Giai đoạn 1: Khởi động & Nghiên cứu (Tuần 1 - 2)

- **Tuần 1:** Nghiên cứu tổng quan về xử lý ngôn ngữ tự nhiên (NLP) cho tiếng Việt. Tìm hiểu các đặc điểm của lỗi chính tả do gõ máy (Telex/VNI) và lỗi nhận diện ký tự quang học (OCR).
- **Tuần 2:** Tìm hiểu kiến trúc mô hình **Transformer** và cơ chế **Encoder-Decoder**. Nghiên cứu về phương pháp **UniversalRAG** để hỗ trợ truy xuất ngữ cảnh đa cấp độ nhằm tăng độ chính xác.

Giai đoạn 2: Thu thập & Xử lý dữ liệu (Tuần 3 - 4)

- **Tuần 3:** Thu thập tập dữ liệu văn bản tiếng Việt chuẩn (Gold Dataset) từ Wikipedia hoặc báo điện tử. Xây dựng bộ từ điển chuẩn để phục vụ việc kiểm tra lỗi.

- **Tuần 4:** Viết chương trình tự động tạo lỗi (Noising) để tạo tập dữ liệu huấn luyện. Tập trung vào việc thay đổi ký tự theo quy luật OCR (như 'o' thành '0', 'l' thành 'i') và lỗi gõ phím.

Giai đoạn 3: Huấn luyện mô hình (Tuần 5 - 7)

- **Tuần 5:** Thiết lập môi trường lập trình (Python, PyTorch/Hugging Face). Khởi tạo mô hình tiền huấn luyện như **ViT5** hoặc **BARTpho**.
- **Tuần 6:** Thực hiện quá trình **Fine-tuning** (tinh chỉnh) mô hình trên tập dữ liệu đã tạo. Áp dụng các kỹ thuật như *Early Stopping* để tránh quá tải (overfitting).
- **Tuần 7:** Tích hợp thành phần **Retriever** của UniversalRAG. Xây dựng kho dữ liệu vector để mô hình có thể truy xuất các cụm từ đúng khi gặp từ lạ hoặc lỗi OCR nặng.

Giai đoạn 4: Đánh giá & Tối ưu hóa (Tuần 8 - 9)

- **Tuần 8:** Chạy kiểm thử trên tập dữ liệu Test. Tính toán các chỉ số độ chính xác (Accuracy), Precision và Recall. Kiểm tra xem đã đạt mốc **85%** hay chưa.
- **Tuần 9:** Phân tích các lỗi mà hệ thống vẫn mắc phải (Error Analysis). Tinh chỉnh lại bộ **Router** trong UniversalRAG để cải thiện việc chọn lọc thông tin truy xuất.

Giai đoạn 5: Hoàn thiện & Đóng gói (Tuần 10)

- **Tuần 10:** Đóng gói mã nguồn lên **GitHub** (như tôi đã hướng dẫn bạn cách dùng lệnh Git trước đó). Hoàn thiện báo cáo Word và chuẩn bị slide bảo vệ dự án.

5. Tài liệu tham khảo

[1] H. V. Do and M. L. Nguyen, "Hierarchical Transformer Encoders for Vietnamese Spelling Correction," 2021..

[2] T. T. Nguyen et al., "VSEC: Transformer-based Model for Vietnamese Spelling Correction," 2021..

[3] Q. Tran and H. Le, "A Vietnamese Spelling Correction System," 2023.

[4] VNTC (Vietnamese Typographical Corpus), "Dữ liệu lỗi chính tả tiếng Việt.".

[5] Viwiki-Spelling Dataset, "Tập dữ liệu sửa lỗi chính tả đầu tiên cho tiếng Việt.".

[6] VietHoang1512/vietnamese-spell-correct-and-text-classify - Công cụ sửa lỗi dùng mạng nơ-ron sâu.

[7] bmd1905/vietnamese-correction - Mô hình tạo văn bản sửa lỗi tiếng Việt.

[8] UniversalRAG, "Diverse Granularity Retrieval-Augmented Generation Framework," 2024..

[9] VietAI, "ViT5: Pretrained Vietnamese Text-to-Text Transformer," 2021..