HỌC VIỆN CÔNG NGHỆ BƯU CHÍNH VIỄN THÔNG

KHOA CÔNG NGHỆ THÔNG TIN

Môn: THỰC TẬP CƠ SỞ

BÁO CÁO BÀI TẬP LỚN

"Xây dựng hệ thống sửa lỗi chính tả cho tiếng Việt"

Sinh viên thực hiện: Phạm Quang Anh

Mã sinh viên: B23DCCN044

Lớp: D23CQCN02-B

Nhóm: 11

Giảng viên hướng dẫn: TS.Kim Ngọc Bách

Hà Nội 2026

LỜI CẢM ƠN

Lời đầu tiên, chúng em xin gửi lời cảm ơn chân thành tới Học viện Công nghệ Bưu chính Viễn thông vì đã tạo điều kiện cho chúng em được tham gia môn học Thực tập cơ sở. Đây là một môn học rất bổ ích và thiết thực, trang bị cho chúng em những kiến thức nền tảng quan trọng trong lĩnh vực Công nghệ thông tin.

Chúng em đặc biệt biết ơn thầy Kim Ngọc Bách, người đã tận tâm dẫn dắt chúng em trong suốt hành trình chinh phục môn học này. Thầy không chỉ truyền đạt những kiến thức chuyên sâu một cách dễ hiểu mà còn nhiệt tình giải đáp mọi thắc mắc, chia sẻ những kinh nghiệm thực tế quý báu, giúp chúng em có cái nhìn toàn diện và sâu sắc hơn.

Quá trình hoàn thành báo cáo bài tập lớn là một thử thách không nhỏ đối với chúng em. Tuy thời gian có hạn và gặp phải không ít khó khăn, nhưng với sự hướng dẫn tận tình của thầy và tinh thần học hỏi, nỗ lực không ngừng, chúng em đã cố gắng hết sức để hoàn thành báo cáo này một cách tốt nhất.

Kính mong thầy đánh giá và góp ý để chúng em có thể rút kinh nghiệm, hoàn thiện bản thân và phát triển hơn nữa trên con đường học tập sắp tới.

I. Kiến trúc Transformer và Cơ chế Encoder-Decoder

1. Kiến trúc Transformer

Transformer là một kiến trúc mạng nơ-ron được giới thiệu bởi Google vào năm 2017 (trong bài báo nổi tiếng *"Attention is All You Need"*). Đây chính là "xương sống" tạo nên cuộc cách mạng AI hiện nay, là nền tảng của các mô hình nổi tiếng như GPT (của ChatGPT), BERT, hay Gemini.

Điểm khác biệt lớn nhất của Transformer so với các công nghệ trước đó (như RNN hay LSTM) là nó **không xử lý dữ liệu theo thứ tự tuần tự** (từ trái sang phải) mà xử lý **toàn bộ cùng một lúc** nhờ vào cơ chế "Chú ý" (Attention).

Hãy tưởng tượng bạn đang thực hiện một phép toán **"chọn lọc thông tin có trọng số"**. Thay vì coi mọi từ trong câu đều quan trọng như nhau, Transformer sử dụng toán học để quyết định xem từ nào cần được "chú ý" nhiều hơn.

Cơ chế Attention: Query, Key, và Value (Q, K, V)

Công thức tính toán Attention: Điểm chú ý (Attention Score) được tính bằng tích vô hướng của Q và K, sau đó chuẩn hóa bằng hàm **Softmax** để tổng các trọng số bằng 1:

$$Attention(Q, K, V) = \text{softmax}\left(\frac{QK^T}{\sqrt{d_k}}\right)V$$

Để hiểu tại sao Transformer lại mạnh mẽ đến vậy, bạn cần biết 3 thành phần cốt lõi:

1.1. Cơ chế Tự chú ý (Self-Attention)

Đây là khả năng giúp mô hình hiểu được mối quan hệ giữa các từ trong một câu, bất kể chúng đứng cách xa nhau bao nhiêu.

- **Ví dụ:** Trong câu *"Con mèo ngồi trên cái chiếu vì **nó** mệt"*. Cơ chế Attention giúp mô hình hiểu chữ **"nó"** đang ám chỉ **"Con mèo"** chứ không phải "cái chiếu".
- Nó tính toán trọng số (độ quan trọng) của các từ khác đối với từ đang xét.

1.2. Xử lý song song (Parallelization)

Vì không phải chờ từ đứng trước xử lý xong mới đến từ đứng sau, Transformer có thể tận dụng tối đa sức mạnh của chip đồ họa (GPU). Điều này giúp việc huấn luyện mô hình trên kho dữ liệu khổng lồ của Internet trở nên khả thi và nhanh chóng.

1.3. Mã hóa vị trí (Positional Encoding)

Do xử lý cùng lúc cả câu, mô hình sẽ bị mất khái niệm "từ nào đứng trước, từ nào đứng sau". Để khắc phục, Transformer cộng thêm một loại tín hiệu toán học vào mỗi từ để đánh dấu vị trí của nó trong câu.

2. Cơ chế Encoder-Decoder

2.1. Cấu trúc Encoder (Bộ mã hóa)

Nhiệm vụ của Encoder là tạo ra các biểu diễn đặc trưng giàu ngữ cảnh từ dữ liệu đầu vào.

- **Multi-Head Attention:** Cho phép mô hình đồng thời tập trung vào các thông tin ở các vị trí khác nhau trong câu. Mỗi "head" sẽ học một khía cạnh ngôn ngữ khác nhau (ngữ pháp, thực thể, ngữ nghĩa).
- **Feed-Forward Network (FFN):** Áp dụng các biến đổi phi tuyến tính để tăng cường khả năng học đặc trưng sâu của mô hình.

- **Residual Connection & Layer Normalization:** Giúp ổn định quá trình huấn luyện và tránh triệt tiêu gradient.

2.2. Cấu trúc Decoder (Bộ giải mã)

Decoder chịu trách nhiệm sinh chuỗi đầu ra dựa trên thông tin từ Encoder và các từ đã được sinh ra trước đó.

- **Masked Self-Attention:** Ngăn chặn việc mô hình "nhìn thấy" các từ trong tương lai khi đang trong quá trình huấn luyện.
- **Encoder-Decoder Attention (Cross-Attention):** Đây là "cầu nối" quan trọng giúp Decoder truy vấn thông tin trực tiếp từ các vector trạng thái của Encoder, giúp việc sinh từ luôn bám sát ngữ cảnh câu gốc.

Kiến trúc Tổng thể UniversalRAG cho Tiếng Việt

Hệ thống được vận hành theo cơ chế "Truy xuất trước - Hiệu chỉnh sau", chia làm 3 tầng xử lý chính:

A. Tầng Tri thức Đa cấp độ (Multi-granularity Knowledge Base)

Thay vì chỉ lưu trữ các đoạn văn dài, kho tri thức được cấu trúc thành các hạt nhân dữ liệu khác nhau:

- **Level 1 (Token/Entity):** Danh mục từ vựng chuẩn, tên riêng địa danh, tên người, và các thực thể chuyên biệt (Y học, Luật, Kỹ thuật).
- **Level 2 (Phrase/N-gram):** Các cụm từ cố định, thành ngữ, và các tổ hợp từ thường đi cùng nhau (Collocations) để đối chiếu ngữ cảnh hẹp.
- **Level 3 (Paragraph/Document):** Các đoạn văn bản mẫu chuẩn mực để cung cấp phong cách ngôn ngữ và ngữ cảnh rộng.

---

2. Cơ chế Smart Router (Bộ điều hướng thông minh)

Đây là "bộ não" quyết định hiệu suất của hệ thống. Khi nhận được một câu đầu vào (ví dụ từ OCR bị lỗi), Router sẽ phân tích:

1. **Phát hiện mức độ nhiễu (Noise Detection):** Nếu câu có quá nhiều ký tự lạ (lỗi OCR nặng), Router sẽ kích hoạt **Level 1** để tìm các từ có khoảng cách chỉnh sửa (Edit Distance) gần nhất.
2. **Phân loại chuyên ngành (Domain Classification):** Nếu xuất hiện các từ khóa lạ nhưng có cấu trúc ổn định, Router sẽ điều hướng truy xuất vào kho dữ liệu **Level 3** của chuyên ngành tương ứng (ví dụ: hồ sơ bệnh án).
3. **Quyết định truy xuất:** Router tính toán số lượng k kết quả cần lấy từ mỗi cấp độ để tối ưu hóa cửa sổ ngữ cảnh (Context Window) cho mô hình Transformer.

---

3. Luồng xử lý chi tiết (Workflow)

$$Input \xrightarrow{Preprocessing} Router \xrightarrow{Retrieve} Prompt \xrightarrow{Transformer} Output$$

Bước 1: Tiền xử lý & Nhận diện lỗi

Sử dụng một mô hình nhỏ (như **Bi-LSTM** hoặc **FastText**) để quét nhanh và đánh dấu các vị trí có xác suất sai chính tả cao hoặc các cụm từ nghi ngờ là lỗi OCR (ví dụ: "chương" thành "chu0ng").

Bước 2: Truy xuất đa cấp độ (Retrieval)

- **Với lỗi OCR:** Truy xuất các từ có âm tiết tương đồng hoặc cấu trúc gõ phím gần giống (VNI/Telex).
- **Với lỗi ngữ cảnh:** Truy xuất các câu mẫu chứa các từ xung quanh vị trí lỗi để xem từ nào phù hợp nhất về mặt ngữ nghĩa.

Bước 3: Hợp nhất & Tăng cường (Augmentation)

Hệ thống tạo ra một Prompt phức hợp cho mô hình ngôn ngữ (LLM/Transformer):

> "Dựa trên ngữ cảnh chuyên ngành Y khoa và các từ vựng đã truy xuất: [Danh sách từ đúng], hãy sửa lại câu sau sao cho đúng chính tả và giữ nguyên ý nghĩa: [Câu lỗi]."

---

4. Ưu điểm trong việc xử lý lỗi OCR và Từ hiếm

- **Vượt qua giới hạn từ điển:** Với lỗi OCR nặng, mô hình Transformer thuần túy dễ bị "lạc lối". UniversalRAG cung cấp các "neo" dữ liệu (anchors) từ kho tri thức giúp mô hình định vị được từ gốc.
- **Tính linh hoạt cao:** Khi có các thuật ngữ mới (ví dụ: tên một loại virus mới hoặc công nghệ mới), bạn chỉ cần cập nhật kho tri thức (Vector DB) mà không cần huấn luyện lại toàn bộ hệ thống.
- **Độ chính xác ngữ nghĩa:** Việc truy xuất ở cấp độ cụm từ (Phrase) giúp phân biệt các từ dễ nhầm lẫn như "sáng lạng" (sai) và "xán lạn" (đúng) dựa trên tần suất xuất hiện trong kho dữ liệu chuẩn.

II. Nghiên cứu phương pháp UniversalRAG

UniversalRAG là một bước tiến so với RAG truyền thống, cho phép hệ thống "nhìn" thấy dữ liệu ở nhiều quy mô khác nhau trước khi đưa ra quyết định sửa lỗi.

3.1. Truy xuất đa cấp độ (Multi-granularity)

Hệ thống tổ chức kho tri thức (Knowledge Base) thành 3 tầng:

1. **Cấp độ Từ/Thực thể (Token/Entity):** Xử lý các lỗi chính tả cơ bản, tên riêng, và lỗi OCR bằng cách tra cứu từ điển chuẩn.
2. **Cấp độ Cụm từ (Phrase):** Cung cấp các kết hợp từ phổ biến (n-grams), giúp sửa các lỗi dùng từ sai ngữ cảnh (ví dụ: *xán lạn* thay vì *sáng lạng*).
3. **Cấp độ Đoạn văn (Paragraph):** Cung cấp phong cách hành văn và ngữ cảnh chuyên ngành (Y tế, Luật, Kỹ thuật) để hỗ trợ các từ hiếm.

3.2. Cơ chế Smart Router (Bộ điều hướng thông minh)

Smart Router đóng vai trò phân loại truy vấn đầu vào:

- Nếu phát hiện lỗi **OCR nặng** (nhiều ký tự lạ): Điều hướng ưu tiên truy xuất cấp độ 1 (Fuzzy matching).

- Nếu phát hiện **từ chuyên ngành**: Điều hướng truy xuất cấp độ 3 để tìm tài liệu tham chiếu tương ứng.
- **Mục tiêu:** Giảm thiểu độ trễ (latency) và tránh làm nhiễu mô hình Transformer bằng những thông tin không cần thiết.

5. Tài liệu tham khảo

[1] H. V. Do and M. L. Nguyen, "Hierarchical Transformer Encoders for Vietnamese Spelling Correction," 2021..

[2] T. T. Nguyen et al., "VSEC: Transformer-based Model for Vietnamese Spelling Correction," 2021..

[3] Q. Tran and H. Le, "A Vietnamese Spelling Correction System," 2023.

[4] VNTC (Vietnamese Typographical Corpus), "Dữ liệu lỗi chính tả tiếng Việt.".

[5] Viwiki-Spelling Dataset, "Tập dữ liệu sửa lỗi chính tả đầu tiên cho tiếng Việt.".

[6] VietHoang1512/vietnamese-spell-correct-and-text-classify - Công cụ sửa lỗi dùng mạng nơ-ron sâu.

[7] bmd1905/vietnamese-correction - Mô hình tạo văn bản sửa lỗi tiếng Việt.

[8] UniversalRAG, "Diverse Granularity Retrieval-Augmented Generation Framework," 2024..

[9] VietAI, "ViT5: Pretrained Vietnamese Text-to-Text Transformer," 2021..