

HỌC VIỆN CÔNG NGHỆ BƯU CHÍNH VIỄN THÔNG
KHOA CÔNG NGHỆ THÔNG TIN



Môn: THỰC TẬP CƠ SỞ
BÁO CÁO BÀI TẬP LỚN

“Xây dựng hệ thống sửa lỗi chính tả cho tiếng Việt”

Sinh viên thực hiện: Phạm Quang Anh

Mã sinh viên: B23DCCN044

Lớp: D23CQCN02-B

Nhóm: 11

Giảng viên hướng dẫn: TS.Kim Ngọc Bách

Hà Nội 2026

LỜI CẢM ƠN

Lời đầu tiên, chúng em xin gửi lời cảm ơn chân thành tới Học viện Công nghệ Bưu chính Viễn thông vì đã tạo điều kiện cho chúng em được tham gia môn học Thực tập cơ sở. Đây là một môn học rất bổ ích và thiết thực, trang bị cho chúng em những kiến thức nền tảng quan trọng trong lĩnh vực Công nghệ thông tin.

Chúng em đặc biệt biết ơn thầy Kim Ngọc Bách, người đã tận tâm dẫn dắt chúng em trong suốt hành trình chinh phục môn học này. Thầy không chỉ truyền đạt những kiến thức chuyên sâu một cách dễ hiểu mà còn nhiệt tình giải đáp mọi thắc mắc, chia sẻ những kinh nghiệm thực tế quý báu, giúp chúng em có cái nhìn toàn diện và sâu sắc hơn.

Quá trình hoàn thành báo cáo bài tập lớn là một thử thách không nhỏ đối với chúng em. Tuy thời gian có hạn và gặp phải không ít khó khăn, nhưng với sự hướng dẫn tận tình của thầy và tinh thần học hỏi, nỗ lực không ngừng, chúng em đã cố gắng hết sức để hoàn thành báo cáo này một cách tốt nhất.

Kính mong thầy đánh giá và góp ý để chúng em có thể rút kinh nghiệm, hoàn thiện bản thân và phát triển hơn nữa trên con đường học tập sắp tới.

Dưới đây là mẫu báo cáo tiến độ tuần (thường dùng để gửi giảng viên hướng dẫn hoặc trưởng nhóm) được viết chuẩn chỉnh, chuyên nghiệp dựa trên đúng tiến độ thực tế bài toán sửa lỗi chính tả/OCR tiếng Việt bằng BARTpho mà bạn đã thực hiện trong tuần này.

I. CÁC CÔNG VIỆC ĐÃ HOÀN THÀNH TRONG TUẦN

1. Xử lý và chuẩn bị dữ liệu cần kě:

- Hoàn thiện và đóng gói thành công tập dữ liệu huấn luyện sạch bao gồm hai file `train_clean.csv` (dung lượng 278.34 MB) và `val_clean.csv` phục vụ cho bài toán sửa lỗi.
- Đảm bảo cấu trúc dữ liệu đầu vào chuỗi-sang-chuỗi (Seq2Seq) ánh sáng rõ ràng giữa câu chứa lỗi (`input`) và câu đích chuẩn ngữ pháp (`output`).

2. Cấu hình và tiến hành huấn luyện mô hình (Fine-tuning):

- Triển khai mã nguồn huấn luyện dựa trên thư viện `Hugging Face Transformers` và khởi tạo mô hình tiền huấn luyện mã nguồn lớn **BARTpho** (`vinai/bartpho-word`).
- Thiết lập đầy đủ các tham số tối ưu phần cứng trong `Seq2SeqTrainingArguments`: Kích hoạt chế độ tính toán song song ma trận 16-bit (`fp16=True`), đóng băng vùng nhớ RAM để đẩy nhanh tốc độ nạp dữ liệu sang GPU (`dataloader_pin_memory=True`), và tích hợp thuật toán tối ưu hóa `adamw_torch_fused`.

- Thực hiện chạy thử nghiệm quá trình cày ngầm (Save Version/Commit) trên nền tảng máy ảo GPU của Kaggle.
3. **Nghiên cứu & Giải quyết các sự cố hệ thống (Xử lý rủi ro):**
- Đã phân tích hành vi đóng gói lưu trữ của Kaggle khi tiến trình huấn luyện bị ngắt giữa chừng (Cancel Session).
 - Xây dựng thành công giải pháp **lưu trữ bền vững**, tích hợp cơ chế đồng bộ tự động **push_to_hub=True** thông qua tài khoản cá nhân Hugging Face định kỳ sau mỗi số bước huấn luyện (**save_steps**) để tránh rủi ro mất mát dữ liệu đệm.
 - Khắc phục triệt để các rào cản bảo mật và xác thực môi trường máy ảo phần cứng liên quan đến GPU.

II. ĐÁNH GIÁ KẾT QUẢ ĐẠT ĐƯỢC

- **Ưu điểm:** Luồng code xử lý dữ liệu và cấu hình Trainer đã chạy thông suốt, không còn gặp lỗi cú pháp hay tràn bộ nhớ VRAM. Đã làm chủ được cơ chế đồng bộ dữ liệu real-time lên Hugging Face Hub.
- **Hạn chế tồn tại:** Thời gian huấn luyện mô hình lớn với dung lượng dữ liệu xấp xỉ 300MB tiêu tốn khá nhiều tài nguyên GPU miễn phí (hệ thống chạy ngầm ~9 tiếng) dẫn đến việc bị cạn kiệt giới hạn thời gian (Quota) trên tài khoản cũ, buộc phải chuyển đổi và cấu hình lại môi trường sang tài khoản dự phòng/Google Colab.

5. Tài liệu tham khảo

- [1] H. V. Do and M. L. Nguyen, "Hierarchical Transformer Encoders for Vietnamese Spelling Correction," 2021..
- [2] T. T. Nguyen et al., "VSEC: Transformer-based Model for Vietnamese Spelling Correction," 2021..
- [3] Q. Tran and H. Le, "A Vietnamese Spelling Correction System," 2023.

[4] VNTC (Vietnamese Typographical Corpus), "Dữ liệu lỗi chính tả tiếng Việt."

[5] Viwiki-Spelling Dataset, "Tập dữ liệu sửa lỗi chính tả đầu tiên cho tiếng Việt."

[6] [VietHoang1512/vietnamese-spell-correct-and-text-classify](#) - Công cụ sửa lỗi dùng mạng nơ-ron sâu.

[7] [bmd1905/vietnamese-correction](#) - Mô hình tạo văn bản sửa lỗi tiếng Việt.

[8] UniversalRAG, "Diverse Granularity Retrieval-Augmented Generation Framework," 2024..

[9] VietAI, "ViT5: Pretrained Vietnamese Text-to-Text Transformer," 2021..