HỌC VIỆN CÔNG NGHỆ BƯU CHÍNH VIỄN THÔNG

KHOA CÔNG NGHỆ THÔNG TIN

Môn: THỰC TẬP CƠ SỞ

BÁO CÁO BÀI TẬP LỚN

"Xây dựng hệ thống sửa lỗi chính tả cho tiếng Việt"

Sinh viên thực hiện: Phạm Quang Anh

Mã sinh viên: B23DCCN044

Lớp: D23CQCN02-B

Nhóm: 11

Giảng viên hướng dẫn: TS.Kim Ngọc Bách

Hà Nội 2026

LỜI CẢM ƠN

Lời đầu tiên, chúng em xin gửi lời cảm ơn chân thành tới Học viện Công nghệ Bưu chính Viễn thông vì đã tạo điều kiện cho chúng em được tham gia môn học Thực tập cơ sở. Đây là một môn học rất bổ ích và thiết thực, trang bị cho chúng em những kiến thức nền tảng quan trọng trong lĩnh vực Công nghệ thông tin.

Chúng em đặc biệt biết ơn thầy Kim Ngọc Bách, người đã tận tâm dẫn dắt chúng em trong suốt hành trình chinh phục môn học này. Thầy không chỉ truyền đạt những kiến thức chuyên sâu một cách dễ hiểu mà còn nhiệt tình giải đáp mọi thắc mắc, chia sẻ những kinh nghiệm thực tế quý báu, giúp chúng em có cái nhìn toàn diện và sâu sắc hơn.

Quá trình hoàn thành báo cáo bài tập lớn là một thử thách không nhỏ đối với chúng em. Tuy thời gian có hạn và gặp phải không ít khó khăn, nhưng với sự hướng dẫn tận tình của thầy và tinh thần học hỏi, nỗ lực không ngừng, chúng em đã cố gắng hết sức để hoàn thành báo cáo này một cách tốt nhất.

Kính mong thầy đánh giá và góp ý để chúng em có thể rút kinh nghiệm, hoàn thiện bản thân và phát triển hơn nữa trên con đường học tập sắp tới.

1. Mục tiêu tuần 4

- Hoàn thiện bộ tiền xử lý dữ liệu sạch (Gold Dataset).
- Xây dựng module gây nhiễu (Noising System) đa dạng quy luật: OCR, Telex, Keyboard, Swap.
- Áp dụng kỹ thuật **Exhaustive Data Augmentation** (Tăng cường dữ liệu vét cạn) để tạo tập Training Dataset chất lượng cao.

---

2. Nội dung thực hiện

2.1. Xây dựng bộ quy luật gây nhiễu (Advanced Noiser)

Hệ thống được thiết kế dựa trên lớp **AdvancedVietnameseNoiser** với 4 nhóm quy luật chính mô phỏng hành vi sai lỗi của người dùng thực tế:

- **Lỗi Telex (Trọng tâm):** Mô phỏng việc quên gõ dấu hoặc gõ sai quy tắc Telex
- **Lỗi OCR:** Mô phỏng sự nhầm lẫn giữa các ký tự có hình dáng tương đồng
- **Lỗi Bàn phím (Keyboard Neighbors):** Mô phỏng việc gõ nhầm các phím liền kề trên layout QWERTY
- **Lỗi Tráo đổi (Swap):** Mô phỏng lỗi gõ nhanh dẫn đến đảo vị trí 2 ký tự liền kề.

```python
def __init__(self):
    # 1. Quy luật OCR
    self.ocr_rules = {
        'o': ['0', 'ó'], '0': ['o'],
        'i': ['l', '1'], 'l': ['i', '1'],
        'g': ['9'], 'a': ['4'],
        'e': ['3'], 's': ['5'],
        'u': ['v'], 'v': ['u']
    }
    # 2. Quy luật Telex
    self.telex_map = {
        'â': 'aa', 'ă': 'aw', 'ê': 'ee', 'ô': 'oo',
        'ơ': 'ow', 'ư': 'uw', 'đ': 'dd', 'á': 'as', 'à': 'af',
        'ả': 'ar', 'ã': 'ax', 'ạ': 'aj'
    }
    # 3. Quy luật Bàn phím
    self.kb_neighbors = {
        'h': 'g', 'n': 'm', 'k': 'l', 'u': 'y', 'i': 'o',
        'p': 'o', 't': 'r', 'g': 'f', 's': 'a', 'd': 's'
    }
```

```python
elif current_method == 'swap' and len(word_list) > 1:
    # Lỗi đảo chữ: tráo đổi 2 ký tự liền kề
    i = random.randint(0, len(word_list) - 2)
    word_list[i], word_list[i+1] = word_list[i+1], word_list[i]
    word = "".join(word_list)
```

2.2. Chiến lược tạo dữ liệu "Vét cạn" (Exhaustive Strategy)

Thay vì tạo lỗi ngẫu nhiên, hệ thống áp dụng cơ chế sinh dữ liệu đa chiều. Với mỗi câu chuẩn (Gold Sentence), hệ thống tự động sinh ra 5 biến thể lỗi khác nhau:

1. **Phiên bản lỗi Telex thuần.**
2. **Phiên bản lỗi OCR thuần.**
3. **Phiên bản lỗi Bàn phím.**
4. **Phiên bản lỗi Đảo chữ.**
5. **Phiên bản lỗi hỗn hợp (Random Noise).**

Kết quả: Tập dữ liệu huấn luyện được nhân bản gấp **5 lần** so với dữ liệu gốc, đảm bảo độ phủ lỗi tối đa cho mô hình.

	source	target
163	Ở hướn9 nghiên cứu sau, trí tvệ nhân tạo có th...	Ở hướng nghiên cứu sau, trí tuệ nhân tạo có th...
23	Policy rối uy có rhể được tíng toán một cách h...	Policy tối ưu có thể được tính toán một cách h...
126	Trước đó, đoàn đạl biểu củ4 chương trình kỷ ni...	Trước đó, đoàn đại biểu của chương trình kỷ ni...
174	Tuy nhieen, ranh giới giữa 5 buwớc xử lý nafy ...	Tuy nhiên, ranh giới giữa 5 bước xử lý này cũn...
596	43 Trong kế hoạch cổ iđển, tác nhân được giar ...	34 Trong kế hoạch cổ điển, tác nhân được giả đ...
37	9 Tư tuwởng có khả năng sinh ậvt nhân tạo xuất...	g Tư tưởng có khả năng sinh vật nhân tạo xuất ...
791	Trớưc ớđ, chiuề ớti gnày 42 ,3 kih hpát hệin đ...	Trước đó, chiều tối ngày 24 3, khi phát hiện đ...
740	Theo Biil Jóy, người đồng sán9 lập và Glám đốc...	Theo Bill Joy, người đồng sáng lập và Giám đốc...
625	72 Trí tvệ nhân tạo 4I chi4 thành h4i trườn9 p...	72 Trí tuệ nhân tạo AI chia thành hai trường p...
173	29 Trong khl đó, Mar9aret Masterman ch0 rằng c...	29 Trong khi đó, Margaret Masterman cho rằng c...

2.3. Chiến lược đảm bảo tính khách quan và chống Overfitting

Để mô hình không bị phụ thuộc vào thứ tự dữ liệu nguồn (Bias) và có khả năng tổng quát hóa (Generalization) tốt nhất, hệ thống áp dụng quy trình xáo trộn dữ liệu hai tầng:

1. **Xáo trộn nguồn (Input Shuffling):** Sử dụng hàm random.shuffle(lines) ngay sau khi đọc file gold_data_wikipedia.txt. Bước này đảm bảo các chủ đề (AI, Công nghệ, Đời sống) được trộn đều ngay từ đầu, tránh việc mô hình học theo cụm chủ đề cố định.
2. **Xáo trộn tập huấn luyện (DataFrame Sampling):** Sau khi tạo ra 810 cặp câu lỗi bằng phương pháp vét cạn, toàn bộ dữ liệu được xáo trộn một lần nữa bằng lệnh

```
df = pd.DataFrame(dataset).sample(frac=1).reset_index(drop=True)
```

   - **Mục tiêu:** Phá vỡ tính tuần tự của các loại lỗi (ví dụ: không để 5 biến thể của cùng một câu gốc nằm cạnh nhau).
   - **Kết quả:** Khi huấn luyện, mỗi "batch" dữ liệu sẽ chứa các loại lỗi và nội dung hoàn toàn khác nhau, buộc mô hình phải thực sự học quy luật ngôn ngữ thay vì ghi nhớ máy móc vị trí dòng.

3. Kết quả đạt được

- **Dữ liệu nguồn:** Crawl từ Wikipedia, VnExpress, Báo Nhân Dân (Chủ đề AI, Công nghệ, Đời sống).
- **Số lượng câu chuẩn (Gold):** ~162 câu (sau khi lọc).
- **Số lượng cặp Train (Source - Target): 810 cặp câu.**
- **Định dạng lưu trữ:** train_data.csv (UTF-8-SIG)
-

	source	target
15	58 Lĩnh vực này b4o quát nhiều hướng nghiên cứ...	58 Lĩnh vực này bao quát nhiều hướng nghiên cứ...
510	Duwới đaay laf một số trong nhiều nhaf nghieen...	Dưới đây là một số trong nhiều nhà nghiên cứu ...
248	ửX ýl nôgn nữg ựt nhinê antural lanugage proce...	Xử lý ngôn ngữ tự nhiên natural language proce...
3	rfe Nhữgn nhnâ ậvt nyà àv ốs pậhn caủ ọh ênu a...	ref Những nhân vật này và số phận của họ nêu r...
252	Các đặc tính được mô tả dưới đây đã nhận được ...	Các đặc tính được mô tả dưới đây đã nhận được ...
406	73 Hoặc cũng có thể vấn ddề thất nghiệp sẽ duw...	73 Hoặc cũng có thể vấn đề thất nghiệp sẽ được...
27	05 ộMt ốs nứg dnụg tiuê bểiu caủ LNP abo gmồ n...	50 Một số ứng dụng tiêu biểu của NLP bao gồm n...
391	Trong diễn văn kỷ niệm taji buổi lễ, đồng chí ...	Trong diễn văn kỷ niệm tại buổi lễ, đồng chí B...
302	Ông Daniel Panov cho biết aẽ gửi lờ1 mời đoàn ...	Ông Daniel Panov cho biết sẽ gửi lời mời đoàn ...
701	44 Tráo lại, gọc có goám sár yêy cầy sữ liệu h...	44 Trái lại, học có giám sát yêu cầu dữ liệu h...

5. Tài liệu tham khảo

[1] H. V. Do and M. L. Nguyen, "Hierarchical Transformer Encoders for Vietnamese Spelling Correction," 2021..

[2] T. T. Nguyen et al., "VSEC: Transformer-based Model for Vietnamese Spelling Correction," 2021..

[3] Q. Tran and H. Le, "A Vietnamese Spelling Correction System," 2023.

[4] VNTC (Vietnamese Typographical Corpus), "Dữ liệu lỗi chính tả tiếng Việt.".

[5] Viwiki-Spelling Dataset, "Tập dữ liệu sửa lỗi chính tả đầu tiên cho tiếng Việt.".

[6] VietHoang1512/vietnamese-spell-correct-and-text-classify - Công cụ sửa lỗi dùng mạng nơ-ron sâu.

[7] bmd1905/vietnamese-correction - Mô hình tạo văn bản sửa lỗi tiếng Việt.

[8] UniversalRAG, "Diverse Granularity Retrieval-Augmented Generation Framework," 2024..

[9] VietAI, "ViT5: Pretrained Vietnamese Text-to-Text Transformer," 2021..